

R11 接待机器人 VLA 系统设计文档

R11 接待机器人 VLA 系统设计文档

版本：v0.1

适用范围：R11 接待机器人数据转换、VLA 模型训练与评估、本体闭环集成、云端大模型部署与本体小模型部署

1. 背景与目标

VLA 部分覆盖从数据到模型、从模型到本体执行闭环的完整链路。本设计将目标系统抽象为四类关键算法与工程能力：

- 数据转换能力：将 ROS2 MCAP 原始数据转换为可训练的数据集，支持多批次数据汇总与验收。
- 模型算法与训练能力：提供 VLA 基座模型、数据格式约定、微调、评估和模型版本管理。
- 推理与部署能力：支撑本体小模型和云端大模型的加载、推理、服务化和部署。
- 本体闭环集成能力：负责把本体小模型或远程云端大模型接入本体任务执行闭环。

本设计文档的目标是给出一套可落地的 VLA 系统设计，使部署在机器人本体上的小模型和部署在云端的大模型共享统一的数据规范、推理接口和任务执行闭环，逐步迭代到真实 R11 接待机器人的稳定运行。

1.1 设计目标

- 建立端到端工作流：以已有 MCAP 数据为输入，完成转换、训练、评估、部署和本体闭环执行。
- 支持两类模型路线：
 - 本体小模型：比如部署在 Orin 上的 FlowerVLA，追求低延迟、离线可运行。
 - 云端大模型：比如 PI0.5、GR00T，追求更强泛化能力和复杂任务能力。
- 统一本体集成接口：无论动作来自本体小模型还是云端大模型，执行层都只感知动作序列。
- 统一数据资产格式：将已有 MCAP 原始数据转换为 LeRobot 可训练、可评估的数据。
- 支持可观测、可回放、可验收：每次数据转换、模型训练、本体/云端推理部署和本体执行都应具备检查手段。

1.2 非目标

- 本文不涉及 MCAP 生成链路，只约定已有 MCAP 数据进入 VLA 链路后的转换、验收和使用方式。

2. 总体工作流

VLA 工作流可按时间顺序划分为五个阶段：准备数据、微调模型、评估模型、部署模型、运行推理与本体闭环执行。结合项目目标，端到端工作流如下：




该流程形成数据飞轮：

1. 上游数据链路提供 ROS2 MCAP 原始数据，作为数据转换阶段的输入。
2. 数据转换工具将已有 MCAP 转换为 LeRobot 格式数据集，完成维度、FPS、图像、任务描述检查。
3. 数据集进入训练链路，分别服务于本体小模型和云端大模型。
4. 训练好的模型先做开环评估，再进入本体闭环测试。
5. 本体执行失败样本和新场景数据回流到数据池，支撑下一轮训练。

3. 系统架构

3.1 分层架构



3.2 核心设计原则

- 数据格式先行：所有模型训练和部署都必须以可复现的数据格式为基础。
- 模型调用可替换：本体小模型、云端大模型、回放策略都通过统一动作生成接口接入，不侵入任务执行主循环。
- 执行闭环最小稳定：本体侧以“观测、决策、生成动作、执行动作、记录结果”为最小闭环。
- 失败可诊断：任何失败都需要能定位到数据、推理、通信、动作执行或任务判定中的某一环。
- 渐进部署：先离线开环评估，可选仿真验证，最后进入真实本体闭环。

4. 数据系统设计

4.1 数据输入来源

VLA 数据链路以已有 ROS2 MCAP 文件作为输入。本文不展开 MCAP 生成链路，仅约定进入转换工具的数据类型主要包含：

- 多路 RGB 相机图像。
- 本体状态。
- 与任务相关的语言描述或标注。
- 用于多模态同步的时间戳；每个输入 MCAP 文件对应一个 Episode。

设计上建议数据转换能力支持多路相机输入；训练初期可以根据模型输入配置只启用其中一到两路，后续再扩展到更多视角。

4.2 数据转换目标

数据转换结果需要满足以下约束：


- 项目机器人类型默认是 `r11`，允许通过参数覆盖。
- 输出 FPS 默认是 15；当源 FPS 高于 15 时按总时长均匀下采样。
- 图像统一为 `480x640x3` 的 RGB `uint8`。
- `observation.state` 与 `action` 统一为 16 维。
- 支持多个日期或批次的数据集汇总。
- 每个 Episode 绑定任务语言描述，供 VLA 模型学习语言条件动作。

16 维状态/动作顺序为：

代码块

```
1  右臂 7 关节 + 右手开合 + 左臂 7 关节 + 左手开合
```

4.3 数据处理流程



关键处理逻辑：

- 图像解码需要按照 ROS Image 的 `step` 字段解析，避免行填充导致图像错位。
- BGR 输入统一转换为 RGB，避免模型看到错误颜色通道。

- 状态提取使用显式关节索引，避免切片导致左右臂顺序误解。
- 时间对齐采用最近时间戳匹配策略，确保图像、状态和动作按照同一帧组织。

4.4 数据验收

每次 MCAP 转换或数据集汇总后必须执行基础验收。建议保留以下检查项：

- 检查数据集元信息：机器人类型为 `r11`，`fps` 为 15，状态和动作维度为 `[16]`，图像存储尺寸为 `[480, 640, 3]`。
- 抽样读取数据：确认 LeRobot 数据集可正常加载，样本中的图像、状态、动作字段齐全，图像视角和颜色通道符合预期。
- 检查任务标注：确认每个 Episode 绑定正确任务描述，一个输入 MCAP 对应一个 Episode。
- 检查汇总结果：确认多批次数据汇总后 Episode 数、帧数、任务列表符合预期。

5. 模型系统设计

5.1 双模型部署路线

系统同时支持部署在本体上的小模型和部署在云端的大模型：

- 本体小模型：
 - 代表模型：FlowerVLA。
 - 目标硬件：Jetson Orin。
 - 优先目标：低延迟、低依赖、离线可运行。
 - 适用场景：高频短程操作、固定任务、已知场景。
- 云端大模型：
 - 代表模型：PI0.5、GR00T。
 - 目标运行环境：云端或机房 GPU 服务器。
 - 优先目标：更强泛化、更强语言理解、更强视觉语义能力。
 - 适用场景：复杂任务、多物体、多步骤、需要大模型能力的场景。

两类部署形态在本体侧不直接暴露差异，统一抽象为：


代码块

```
1 ObservationSnapshot + Task -> Action Sequence
```

也就是说，模型可以在本体上加载，也可以通过网络调用云端服务；只要返回统一动作序列，即可接入同一套闭环调度逻辑。

5.2 FlowerVLA 本体小模型路线

FlowerVLA 用于本体侧的 Orin 小模型部署，其接入方式可抽象为“观测输入、模型推理、动作序列输出”：




本地推理关键要求：

- 模型包必须包含推理所需的权重、配置和归一化统计。
- 输入图像来自 ROS Image，需要在推理 API 中完成格式转换。
- 输出动作序列需要转换为本体控制器可理解的动作格式。
- 本体 Orin 部署时应控制图像尺寸、批大小、模型精度和动作预测步长，以满足实时性。

5.3 云端大模型路线

云端大模型包括 GR00T N1.7，以及基于 LeRobot 训练的 PI0.5、ACT 等策略模型。此类模型通过统一推理服务对外提供动作预测能力。本体侧将图像、状态和任务描述打包成请求，从云端获取动作序列。



云端推理服务可优先接入已验证的策略模型，后续扩展到更大规模的 VLA 模型。为降低本体侧适配复杂度，云端应统一输出反归一化后的物理动作值。

5.4 训练与评估策略

训练分为三个阶段：

- 阶段一：离线数据可用性验证。
 - 使用少量 Episode 跑通数据加载、字段映射和单卡训练。
 - 目标不是效果，而是确认数据格式、输入字段、维度和统计信息正确。
- 阶段二：任务级微调。
 - 按任务类别组织数据，比如抓取、放置、递送、开合手。
 - 每个任务保留未参与训练的日期或场景作为验证集。
 - 对本体小模型和云端大模型分别训练，记录成功率、推理延迟和资源消耗。
- 阶段三：本体闭环验证。
 - 先使用回放测试动作接口，仿真验证作为可选项。
 - 再在真实本体上低速、限幅、有人值守执行。
 - 失败样本进入数据回流队列。

评估指标：

- 开环：
 - MSE / MAE。
 - 分关节误差。
 - 动作预测步长内的误差增长趋势。
- 闭环：
 - 任务成功率。
 - 平均完成步数。
 - 平均推理耗时与 P90/P99 耗时。
 - 动作执行失败率。
 - 人工接管次数。
- 工程稳定性：
 - 模型加载时间。
 - 服务可用性。
 - 网络超时率。
 - 数据转换失败率。


6. 本体集成设计

6.1 闭环执行抽象

本体执行框架由四类抽象组件组成：

- 观测模块：保存状态和图像观测，按时间条件返回最新对齐快照。
- 决策模块：基于观测、动作历史和执行结果判断任务成功、失败或继续。
- 动作生成模块：基于任务和观测生成动作序列，可以由本体小模型、云端大模型或回放策略实现。
- 动作执行模块：负责动作下发，在动作满足完成条件后返回执行结果。

闭环调度模块负责任务主循环：



6.2 观测设计

观测快照设计包含：

- `state`：带纳秒时间戳的本体状态。

- `image`：主图像观测。
- `image2`：可选第二路图像观测。

观测模块使用线程安全缓存保存状态和图像，在读取时完成对齐。基础对齐逻辑以状态为基准，选择时间戳不晚于状态且最接近状态的图像。

后续扩展：

- 支持多路图像字典，而不是固定 `image` / `image2`。
- 引入最大时间差阈值，比如图像与状态差距超过 100ms 时拒绝生成快照。
- 为每个快照记录相机名、状态来源、同步误差，便于诊断。

6.3 动作设计

动作模型抽象为：

代码块

```
1  Action = {  
2      "type": "joint_position",  
3      "positions": list[float]  
4  }
```

与 16 维关节/手部状态设计一致。动作执行时应满足：

- 输出维度必须与本体控制器期望一致。
- 动作值必须完成反归一化，本体侧不应接收模型归一化空间数值。
- 执行器不能在下发命令后立即返回，应持续检查状态，直到达到误差阈值或超时。
- 需要支持限幅、速度限制、动作平滑和急停。

6.4 决策模块设计


初期使用简单规则让任务执行由最大动作数终止。但真实本体部署需要逐步增强：

- 成功判定：
 - 视觉检测目标物是否到位。
 - 末端或手部状态是否进入稳定区间。
 - 连续 N 帧满足条件才判定成功。
- 失败判定：
 - 动作执行误差连续超限。
 - 长时间没有新观测。
 - 模型连续无法返回动作。

- 人工急停或安全模块触发。
- 动作修正：
 - 关节插值，减少动作突变。
 - 手部开合防抖，避免误预测导致物品掉落。
 - 接近关节限时时做限幅或拒绝执行。

6.5 本体与云端动作生成适配

本体小模型和远程大模型都通过统一动作生成适配层接入：



统一动作生成接口将模型选择与任务主循环解耦：

- 本体小模型模式：在本体侧加载模型包，根据实时观测生成动作序列。
- 云端大模型模式：将观测编码为 HTTP 请求，通过云端推理服务获取动作序列。
- 回放模式：将历史状态或动作记录作为动作来源，用于验证执行链路。

7. 云端推理服务设计

7.1 服务职责

云端推理服务负责加载指定模型，对外提供动作预测能力。服务启动时需要读取模型路径、模型类型、推理设备、机器人类型等配置。

核心接口：

- 健康检查接口：返回服务状态、模型类型、模型版本和推理设备。
- 动作预测接口：接收状态、图像和任务描述，返回动作序列。

7.2 请求与响应

请求格式：

代码块

```
1  {
2    "state": [0.0, 0.0, 0.0],
3    "images": {
4      "left": "<base64 image>",
5      "front": "<base64 image>"
6    },
7    "task": "pick up bottle"
8  }
```

服务端需要将相机 Key 规范化到模型期望的输入命名，对缺失视角、空任务、状态维度错误等情况返回明确错误。


响应格式：

代码块

```
1  {
2    "action": [
3      [0.0, 0.0, 0.0],
4      [0.1, 0.0, 0.0]
5    ]
6  }
```

其中 `action` 表示动作片段，外层是时间维，内层是单步动作维度。

7.3 服务内部流程



早期建议使用单模型实例，通过推理资源锁保护推理过程。如果已有请求正在推理，新请求应快速失败或按短超时策略处理。这种策略适合早期本体闭环，因为明确失败优于请求排队造成动作滞后。


后续可演进方向：

- 支持请求队列和超时丢弃策略。

- 支持多模型多实例路由。
- 支持批量推理，但本体实时闭环默认仍建议单请求低延迟。

8. 部署拓扑

8.1 本体小模型部署




优点：

- 网络依赖低。
- 推理路径短，延迟可控。
- 适合基础技能和稳定场景。

约束：

- 模型规模受 Orin 显存、算力和散热限制。
- 复杂语义任务能力弱于云端大模型。
- 需要更严格的模型压缩、量化或 TensorRT 优化。

8.2 云端大模型部署



优点：

- 可运行更大模型。
- 模型升级不需要频繁改本体环境。
- 便于集中记录推理日志和模型版本。


约束：

- 网络延迟和抖动可能影响动作实时性。

- 服务不可用时需要降级策略。
- 图像 Base64 传输增加带宽和 CPU 开销。

8.3 混合部署

推荐长期目标是混合部署：



策略建议：

- 默认使用本体小模型完成高频控制或简单动作。
- 对复杂语言任务、泛化任务调用云端模型。
- 云端超时或返回 503 时，不应继续使用旧动作无限执行；应触发重试、减速或安全停止。
- 对云端返回的动作仍需本地安全过滤。

9. 接口契约

9.1 数据转换接口

数据转换能力需要提供以下输入参数：

- 输入 MCAP 文件路径或目录。
- 输出数据集目录。
- 数据集标识和机器人类型。
- 任务语言描述。
- 目标 FPS、图像尺寸和通道数。

- 需要启用的相机视角和状态字段映射。

数据集汇总能力需要提供以下输入参数：

- 多个待汇总数据集路径。
- 汇总后输出目录。
- 汇总后数据集标识。
- Episode、任务标注和统计信息的汇总策略。

9.2 本体侧任务输入

任务描述需要至少包含：

代码块

```
1  {
2    "language_instruction": "右手拿起瓶子，放到桌面左侧",
3    "max_action_count": 400,
4    "max_action_count_per_emit": 5,
5    "refresh_retry_limit": 20,
6    "get_actions_retry_limit": 30,
7    "state_tolerance": 0.02
8  }
```

关键参数含义：

- `language_instruction`：语言任务描述，进入 VLA 模型。
- `max_action_count`：任务最多执行多少个动作，防止无限循环。
- `max_action_count_per_emit`：每次模型返回动作片段后最多执行多少步，避免长期执行过计划。
- `refresh_retry_limit`：观测不可用时的重试上限。
- `get_actions_retry_limit`：模型无法返回动作时的重试上限。
- `state_tolerance`：动作完成检查的关节误差阈值。

9.3 云端推理接口

请求：

代码块

```
1  {
2    "state": [0.0, 0.0, 0.0, 0.0],
3    "images": {
4      "front": "<base64 image>",
```

```
5     "left": "<base64 image>"
6   },
7   "task": "pick up bottle"
8 }
```

响应：

代码块

```
1  {
2    "action": [[0.0, 0.0, 0.0, 0.0]]
3  }
```

错误约定：

- 请求字段错误、缺少模型需要的图像 Key、任务为空时，返回参数错误。
- 模型服务尚未就绪，或已有推理请求正在执行时，返回服务暂不可用。
- 模型推理内部失败时，返回推理失败，记录服务端日志。

10. 安全与稳定性设计

真实本体部署必须将模型输出视为“建议动作”，而不是直接可信控制命令。安全设计建议分层实现：

10.1 动作安全过滤

在动作执行模块下发前执行：

- 维度检查：动作维度必须等于控制器期望维度。
- 数值检查：拒绝 NaN、Inf 和异常大值。
- 关节限位：每个关节必须在机械限位内。
- 单步限幅：相邻动作差值不得超过速度/加速度上限。
- 手部动作防抖：抓取后避免单帧误预测导致打开。

10.2 观测安全

- 图像和状态必须都有新时间戳。
- 图像与状态的时间差超过阈值时，不生成模型输入。
- 长时间无新状态时进入安全停止。
- 关键传感器缺失时降级或拒绝执行。

10.3 服务安全

- 云端推理设置请求超时。
- 服务繁忙时本体侧应快速失败，进入重试/安全策略。
- 模型版本、请求耗时、返回动作统计应写入日志。
- 不应在请求日志中直接保存大体积图像载荷；如需留存，应采样保存、脱敏处理。

10.4 人机协作安全

- 初期真实本体测试必须有人值守。
- 提供物理急停和软件急停。
- 新模型首次上线必须使用低速、低幅度、安全区域。
- 每个任务设置最大执行步数和最大执行时间。

11. 可观测性与日志

建议在三个层面记录日志：

11.1 数据日志

- MCAP 文件路径、数据日期、任务描述、操作者。
- 转换参数：FPS、图像尺寸、机器人类型。
- 转换结果：Episode 数、帧数、总时长、失败原因。
- 数据校验结果：状态/动作维度、任务标注、相机帧读取结果。

11.2 推理日志

- 模型类型、模型路径、模型版本。
- 输入状态维度、图像字段、任务文本。
- 推理耗时、预处理耗时、后处理耗时。
- 返回动作序列长度和动作维度。
- 错误码与异常堆栈。

11.3 执行日志

- 任务 ID、语言指令。
- 每步动作、执行开始/结束时间。
- 动作完成误差。
- 决策模块判定结果。
- 人工接管、急停、超时和模型失败事件。

这些日志应能支持从一次本体执行失败回溯到具体模型版本、输入观测、动作输出和数据来源。

12. 迭代路线

12.1 第一阶段：链路打通

目标：确保数据、训练、推理和本体集成最小闭环跑通。

- 使用少量 R11 MCAP 数据跑通数据转换。
- 补齐训练入口所需的数据字段映射和配置。
- 使用本体小模型跑通单模型训练或加载。
- 使用云端模型适配层调通动作预测链路。
- 使用回放策略或低风险控制器验证动作序列。

验收标准：

- 数据集可以被训练和评估链路正常读取。
- 模型服务健康检查正常。
- 动作预测接口可以返回正确维度的动作序列。
- 闭环调度模块能完成一次观测、推理、动作执行闭环。

12.2 第二阶段：任务级闭环

目标：完成固定任务的真实本体闭环。

- 为 1 到 3 个固定任务准备足够 MCAP 数据，完成转换与验收。
- 训练 FlowerVLA 本体小模型和至少一个云端大模型。
- 实现真实动作执行模块，支持动作完成检查。
- 增强决策模块，加入基本成功/失败判定。
- 记录闭环成功率和失败样本。

验收标准：

- 固定任务在受控环境下达到稳定成功率。
- 推理 P90 延迟满足动作频率要求。
- 动作执行失败能被明确记录和诊断。

12.3 第三阶段：泛化与混合部署

目标：将系统扩展到更多任务和更复杂场景。

- 扩充跨日期、跨物体、跨背景数据。
- 引入面向 R11 的新机器人形态微调。

- 建立本体/云端模型路由策略。
- 支持云端不可用时本体侧降级。
- 建立周期性数据回流与再训练机制。

验收标准：

- 新物体、新位置、新背景下成功率有可量化提升。
- 云端服务故障不应导致本体失控。
- 数据、模型、部署版本能完整追踪。

13. 风险与待决问题

13.1 云端实时性风险

云端模型通过 HTTP + Base64 传图，存在延迟和抖动。本体侧不应依赖云端模型做高频低层控制。

短期建议：

- 每次只执行动作序列前几步，通过单次最大执行步数控制计划新鲜度。
- 设置严格超时，比如 4 秒以内。
- 云端失败时停止或切换本体小模型，而不是继续执行旧动作队列。

14. 总结

本设计将 R11 接待机器人 VLA 系统拆为数据层、模型层、推理服务层和本体集成层。数据层以 MCAP 到标准训练数据集为核心，模型层同时支持本体 Orin 小模型和云端大模型，推理服务层提供统一动作序列接口，本体集成层通过闭环调度模块完成观测、决策、动作生成和动作执行闭环。

短期最关键的工作是统一数据格式、跑通固定任务闭环，补齐真实动作执行模块与基础安全策略。中长期目标是建立数据回流机制和本体/云端混合模型路由，让本体在稳定性和泛化能力之间取得平衡。